

การจัดกลุ่มความคิดเห็นโดยใช้เทคนิค **TF-IDF** และอัลกอริทึมการจัดกลุ่มแบบ **Agglomerative**

Text comments clustering using TF-IDF with Agglomerative Clustering Algorithm

จิรภัทร พัฒนสุขชัย¹, ธนภัทร ฝอยทอง¹, ชวาลศักดิ์ เพชรจันทร์ฉาย

¹สาขาวิทยาการคอมพิวเตอร์ คณะวิทยาการคอมพิวเตอร์และเทคโนโลยีสารสนเทศ มหาวิทยาลัยราชภัฏรำไพพรรณี

Emails : u6511011660010@mail.dusit.ac.th*, Thanaphat.foithong@gmail.com,
Chawalsak@outlook.com

AUCC2026
CONFERENCE



4-6 February 2026



Rambhai Barni Rajabhat University

บทนำ

ในปัจจุบัน แพลตฟอร์มวิดีโอออนไลน์มีข้อมูลความคิดเห็นจำนวนมากจากผู้ใช้งาน ซึ่งสามารถนำมาวิเคราะห์เพื่อสร้างประโยชน์ได้ โดยเทคนิคสำคัญที่ใช้คือ การจัดกลุ่มข้อความ (Text Clustering) ซึ่งอาศัยการแปลงข้อความเป็นเวกเตอร์ เช่น TF-IDF และนำไปจัดกลุ่มด้วยอัลกอริทึมต่าง ๆ เช่น K-Means หรือ Agglomerative Clustering เพื่อจำแนกความคิดเห็นตามความคล้ายคลึงของเนื้อหา

งานวิจัยนี้มุ่งเน้นการนำ TF-IDF ร่วมกับ Agglomerative Clustering เพื่อจัดกลุ่มความคิดเห็นจากวิดีโอ YouTube[®] และเปรียบเทียบประสิทธิภาพกับ K-Means โดยมีเป้าหมายเพื่อค้นหารูปแบบหรือเนื้อหาที่คล้ายกันในคอมเมนต์จำนวนมาก ช่วยให้สรุปความคิดเห็นของผู้ชมได้อย่างเป็นระบบ และสามารถต่อยอดสู่การวิเคราะห์ขั้นสูงในอนาคต เช่น การวิเคราะห์ความรู้สึกหรือการจัดอันดับคุณภาพความคิดเห็น คำสำคัญ – การจัดกลุ่มข้อความ, เทคนิค Term Frequency – Inverse Document Frequency, การประมวลผลข้อความ, การจัดกลุ่มแบบ Agglomerative, การจัดกลุ่มแบบ K-Means

วัตถุประสงค์

- 1) เพื่อแปลงข้อมูลความคิดเห็นให้อยู่ในรูปแบบเวกเตอร์ เชิงตัวเลขด้วย **TF-IDF** สำหรับการจัดกลุ่มข้อความตามความคล้ายคลึงกัน
- 2) เพื่อจัดกลุ่มความคิดเห็นของผู้ใช้ด้วยการจัดกลุ่มแบบ **Agglomerative**

ขั้นตอนการดำเนินงาน

1. ข้อมูลที่ใช้ในการศึกษา

- งานศึกษานี้ใช้ชุดข้อมูลความคิดเห็นจาก *YouTube® Comments Labeled Dataset* โดยสุ่มเลือกบางส่วนเพื่อให้เหมาะสมต่อการประมวลผล โดยใช้ข้อมูล 10,000 รายการสำหรับ **Agglomerative Clustering** (เนื่องจากใช้ทรัพยากรสูง) และ 100,000 รายการสำหรับ **K-Means** (รองรับข้อมูลขนาดใหญ่ได้ดีกว่า) ข้อมูลที่ใช้คือคอลัมน์ *comment_text* ซึ่งผ่านการประมวลผลข้อความและแปลงเป็นเวกเตอร์ด้วย **TF-IDF** ก่อนนำไปจัดกลุ่มเพื่อศึกษารูปแบบและความคล้ายคลึงของความคิดเห็นผู้ใช้งาน

comment_text
This video is amazing!
I hate this content, waste of time.
You are so dumb!!!
Click here for free money!!!

ขั้นตอนการดำเนินงาน



2 ขั้นตอนการเตรียมข้อมูล

การเตรียมข้อมูลเริ่มจากการใช้ **Python** ผ่าน **Jupyter Notebook** เพื่ออ่านไฟล์ **CSV** จากนั้นทำการ **Preprocessing** ได้แก่ แปลงข้อความเป็นตัวพิมพ์เล็ก ลบลิงก์ สัญลักษณ์พิเศษ ช่องว่างเกิน ข้อความซ้ำ และ คำที่สั้นเกินไป ก่อนแปลงข้อความทั้งหมดเป็นเวกเตอร์เชิงตัวเลขด้วย **TF-IDF** พร้อมลบ **stop words** อัตโนมัติ เพื่อให้เหลือเฉพาะคำที่มีความหมายสำคัญต่อการจัดกลุ่มความคิดเห็น

ขั้นตอนการดำเนินงาน

3 ขั้นตอนการหาคลัสเตอร์ที่เหมาะสม

การกำหนดจำนวนคลัสเตอร์ที่เหมาะสมสำหรับ Agglomerative Clustering ใช้ทั้งการพิจารณา Dendrogram และการประเมินเชิงปริมาณด้วย Silhouette Score โดยจากการสร้าง Dendrogram ด้วยข้อมูลตัวอย่าง 2,000 แถว (ใช้ Cosine Distance และ Average Linkage) พบค่า Auto Threshold ประมาณ 7.612 และปรับลดเป็น 5.709 เพื่อให้เห็นโครงสร้างกลุ่มย่อยชัดเจน อย่างไรก็ตาม เนื่องจากข้อมูลจริงมีมากกว่า 9,000 แถว ควรใช้ Dendrogram เพื่อตัดสินจำนวนคลัสเตอร์โดยตรงทำได้ค่อนข้างยาก จึงใช้วิธีคำนวณ Silhouette Score สำหรับ k ตั้งแต่ 2 ถึง 256 พบว่าค่าคะแนนเพิ่มขึ้นต่อเนื่อง และค่าที่เหมาะสมที่สุดคือประมาณ $k = 128$ ซึ่งสะท้อนการแบ่งกลุ่มที่สมดุลและสอดคล้องกับโครงสร้างข้อมูลมากที่สุด



126

CONFERENCE



ขั้นตอนการดำเนินงาน

ในการหาจำนวนคลัสเตอร์ที่เหมาะสม ได้เลือกใช้วิธีเชิงปริมาณแทน **Dendrogram** เนื่องจากข้อมูลมีมากกว่า 9,000 แถว ทำให้กราฟซับซ้อน จึงประเมินด้วยการคำนวณค่า **Distance Threshold** หลายระดับเพื่อหาจำนวนกลุ่มที่เหมาะสม สำหรับ **K-Means** ใช้ทั้ง **Elbow Method** (พิจารณาแนวโน้มค่า **Inertia** จาก $k=2-10$) และ **Silhouette Score** เพื่อประเมินคุณภาพการจัดกลุ่ม ผลลัพธ์พบว่า **Inertia** ลดลงต่อเนื่องตามจำนวน k และสามารถระบุจุดศอกของกราฟเพื่อเลือกจำนวนคลัสเตอร์ที่ให้ความสมดุลระหว่างความแตกต่างระหว่างกลุ่มและความคล้ายภายในกลุ่มได้ดีที่สุด.

K	inertia
1	93417.870992
2	92624.105281
3	92317.389823
4	92198.792341
5	91891.939553
6	91734.066147
7	91581.545423
8	91253.448085
9	91065.343906
10	90798.424818

ขั้นตอนการดำเนินงาน


- การวิเคราะห์ **Elbow Method** พบว่าแม้ค่า **Inertia** ลดลงต่อเนื่องและไม่มีจุดตกที่ชัดเจน แต่ช่วง **k** ประมาณ **5** เริ่มเห็นการชะลอตัวของค่า **Inertia** จึงถูกใช้เป็นค่าคลัสเตอร์เบื้องต้น จากนั้นประเมินด้วย **Silhouette Score** ซึ่งมีค่าเพิ่มขึ้นตามจำนวนคลัสเตอร์ และดีที่สุดที่ **k = 10** แม้คะแนนโดยรวมยังต่ำ เพราะข้อมูลมีความคล้ายกันสูง เมื่อนำผลทั้งสองวิธีมาพิจารณาร่วมกันจึงสรุปว่า **k = 5** เป็นจำนวนคลัสเตอร์ที่สมดุลที่สุดในการแยกกลุ่มสำหรับชุดข้อมูลนี้.



ขั้นตอนการดำเนินงาน

4. ขั้นตอนการจัดกลุ่มข้อมูลโดยใช้ **Agglomerative**


หลังจากได้จำนวนคลัสเตอร์ที่เหมาะสมจากการคำนวณเชิงปริมาณ จึงนำมาใช้ฝึกโมเดล **Agglomerative Clustering** โดยกำหนดระยะทางแบบ **Cosine Distance** และใช้ **Average Linkage** เพื่อรวมความคิดเห็นที่มีความหมายใกล้เคียงกันเป็นกลุ่ม จากนั้นใช้ **TruncatedSVD** เพื่อลดมิติของเวกเตอร์ **TF-IDF** ให้เหลือ 2 มิติ เพื่อให้สามารถแสดงผลการกระจายของข้อมูลได้ชัดเจนขึ้น ผลลัพธ์เมื่อกำหนดจำนวนคลัสเตอร์ **k = 119** แสดงให้เห็นว่าข้อมูลความคิดเห็นถูกแบ่งออกเป็นกลุ่มย่อยจำนวนมาก โดยแต่ละสีในกราฟกระจายแทนคลัสเตอร์ที่แตกต่างกัน ขณะที่แกน **SVD Component 1** และ **Component 2** แสดงทิศทางความแปรปรวนหลักของข้อมูล ซึ่งช่วยให้เห็นรูปแบบการกระจายและการแยกกลุ่มได้อย่างชัดเจน โดยรวมแล้วการจัดกลุ่มมีความสอดคล้องกับโครงสร้างและเนื้อหาจริงของความคิดเห็น ทำให้สามารถระบุแนวโน้มความคล้ายคลึงของข้อความได้อย่างมีประสิทธิภาพ.



ขั้นตอนการดำเนินงาน

5 ขั้นตอนการจัดกลุ่มข้อมูลโดยใช้ *K-Means*

หลังจากระบุจำนวนคลัสเตอร์ที่เหมาะสมด้วย **Elbow Method** และ **Silhouette Score** แล้ว จึงฝึกโมเดล **K-Means** ด้วยค่า **n_clusters = 5** เพื่อจัดกลุ่มความคิดเห็นที่มีความหมายใกล้เคียงกัน พร้อมแสดงผลด้วย **TruncatedSVD** ลดมิติ **TF-IDF** เหลือ **2** มิติเพื่อให้เห็นการกระจายของข้อมูลชัดเจน ผลลัพธ์พบว่าความคิดเห็นถูกแบ่งเป็น **5** กลุ่มหลัก โดยแต่ละสีแทนแต่ละคลัสเตอร์ จุดที่อยู่ใกล้กันสะท้อนถึงเนื้อหาที่คล้ายคลึงกัน ส่วนจุดที่กระจายห่างกันแสดงความแตกต่างของความคิดเห็น แม้บางส่วนจะทับซ้อนกันตามธรรมชาติของข้อมูลข้อความ แต่โดยรวมเห็นขอบเขตของแต่ละคลัสเตอร์ได้ค่อนข้างชัดเจน สะท้อนความหลากหลายของความคิดเห็นในชุดข้อมูล



บทสรุป

การศึกษานี้ใช้เทคนิค TF-IDF เพื่อแปลงความคิดเห็นจาก YouTube[®] ให้อยู่ในรูปเชิงตัวเลขก่อนนำไปจัดกลุ่มด้วย Agglomerative Clustering และ K-Means พร้อมประเมินจำนวนคลัสเตอร์ที่เหมาะสมด้วย Elbow Method และ Silhouette Score ผลลัพธ์พบว่า Agglomerative ให้โครงสร้างการจัดกลุ่มที่ละเอียดและสะท้อนความสัมพันธ์ของข้อความได้ดีกว่า แม้จะใช้ทรัพยากรสูง ขณะที่ K-Means ทำงานรวดเร็วและเหมาะกับข้อมูลขนาดใหญ่ ผลการทดลองชี้ให้เห็นว่าการประยุกต์ใช้ TF-IDF ร่วมกับอัลกอริทึมการจัดกลุ่มสามารถช่วยวิเคราะห์และจัดหมวดหมู่ความคิดเห็นออนไลน์ได้อย่างมีประสิทธิภาพ และสามารถต่อยอดสู่ระบบวิเคราะห์ข้อความอัตโนมัติในอนาคต.